


Pandas 라이브러리 알아보기



Pandas



Matplotlib



Plotly



Seaborn



Pandas 라이브러리 소개



데이터 조작 및 분석을 위한 파이썬 라이브러리

시리즈와 데이터프레임이라는 데이터분석에 유용한 데이터 구조 제공

엑셀의 파이썬 버전



Pandas를 배워야 하는 이유



대용량의 데이터를 처리하기 용이

프로그래밍을 통한 반복적인 작업 및 자동화에 유리

머신러닝/딥러닝 모델에 필요한 데이터 처리



파이썬을 활용한 데이터 분석에서
주로 사용하는 Pandas 라이브러리의 주요 함수(기능)들을 알아보기



대부분의 데이터는 엑셀과 유사한 표 형태로 저장

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256



DataFrame

- Pandas 라이브러리에서 지원하는 자료구조
- 2차원의 행렬 데이터를 표 형태로 저장
- 가로인 행(row)과 세로인 열(column)으로 이루어짐
- 각 행과 열은 인덱스를 가지고 있어
데이터를 쉽게 검색하고 필터링 가능
- NumPy 배열 = 한 가지 타입의 숫자 배열 /
DataFrame = 열마다 타입이 다를 수 있는 표

열(column)

행(row)

index	국어	수학	영어
민수	95	88	96
도윤	72	72	68
서아	83	93	85
연우	89	80	94
하준	100	95	93

- Pandas 라이브러리에서 지원하는 자료구조
- 각 원소는 인덱스와 값으로 이루어짐
- 인덱스는 숫자 또는 문자열로 지정 가능


index	value
0	95
1	72
2	83
3	89
4	100

index	value
민수	95
도윤	72
서아	83
연우	89
하준	100



Series와 DataFrame

데이터프레임(DataFrame)에서 하나의 열 데이터를 추출하면 시리즈(Series)





Pandas 사용 준비하기

Pandas 라이브러리를 사용하기 위해서는 불러오는 작업 필요

```
import pandas as pd
```

pandas 라이브러리를 불러와서, pd라는 별명으로 사용한다는 의미

```
df = pd.read_csv("data.csv")
```

= pd(pandas)에 있는 read_csv() 함수를 사용



다양한 형식의 데이터 파일

- Pandas는 다양한 형식의 데이터 파일을 불러올 수 있음
- 일반적으로 대표적인 데이터 유형은 다음과 같음

상대적으로 소규모 데이터

.CSV	Comma-Separated Values 형식으로, 데이터베이스에서 데이터를 내보낼 때 대표적으로 사용되는 유형
.xls / .xlsx	엑셀 파일 형식으로, 스프레드시트 형식으로 저장된 유형
.json	웹 애플리케이션에서 자주 사용되며, API 통신 / 클라우드 데이터 전송에 많이 사용되는 유형
.xml	데이터를 태그로 구분하여 계층적으로 저장하며, 데이터 교환을 위한 표준 형식 중 하나인 유형



다양한 형식의 데이터 파일

- Pandas는 다양한 형식의 데이터 파일을 불러올 수 있음
- 일반적으로 대표적인 데이터 유형은 다음과 같음 **시스템 간 데이터 통신이나 대규모 데이터베이스**

.CSV	Comma-Separated Values 형식으로, 데이터베이스에서 데이터를 내보낼 때 대표적으로 사용되는 유형
.xls / .xlsx	엑셀 파일 형식으로, 스프레드시트 형식으로 저장된 유형
.json	웹 애플리케이션에서 자주 사용되며, API 통신 / 클라우드 데이터 전송에 많이 사용되는 유형
.xml	데이터를 태그로 구분하여 계층적으로 저장하며, 데이터 교환을 위한 표준 형식 중 하나인 유형

CSV

CustomerID,Name,Email,OrderAmount
1,John Doe,john@example.com,100
2,Jane Smith,jane@example.com,150
3,Emily Davis,emily@example.com,200

XLSX

	A	B	C	D	E	F
1	매출전표					
2						
3	업체명	준하유통		업체코드	A070202	
4						
5	날짜	상품코드	상품명	수량	단가	총금액
6	합계	10,757			13,041,900	
7	2021.1.4	MFVCH	초코우유	101	1,250	126,250
8	2021.1.4	MFVMC	민초맛우유	301	1,300	391,300
9	2021.1.8	M0000	우유	57	1,100	62,700
10	2021.1.11	M0000	우유	253	1,100	278,300
11	2021.1.12	M0000	우유	160	1,100	176,000
12	2021.1.13	MFVSB	딸기우유	256	1,200	307,200
13	2021.1.15	MFVMC	민초맛우유	295	1,300	383,500
14	2021.1.21	MFVBN	바나나우유	391	1,300	508,300
15	2021.1.24	MFVSB	딸기우유	70	1,200	84,000
16	2021.1.25	MFVSB	딸기우유	248	1,200	297,600
17	2021.1.27	MFVBN	바나나우유	304	1,300	395,200
18	2021.1.28	MFVMC	민초맛우유	268	1,300	348,400
19	2021.1.29	MFVCH	초코우유	181	1,250	226,250
20	2021.1.30	M0000	우유	328	1,100	360,800
21	2021.2.4	M0000	우유	165	1,100	181,500
22	2021.2.5	M0000	우유	297	1,100	326,700
23	2021.2.6	M0000	우유	253	1,100	278,300
24	2021.2.6	MLF00	저지방우유	186	1,150	213,900
25	2021.2.10	MFVMC	민초맛우유	249	1,300	323,700



JSON

```
{
  "CustomerID": [1, 2, 3],
  "Name": ["John Doe", "Jane Smith",
"Emily Davis"],
  "Email": ["john@example.com",
"jane@example.com",
"emily@example.com"],
  "OrderAmount": [100, 150, 200]
}
```

XML

```
<?xml version="1.0" ?>
<Customers>
  <Customer>
    <CustomerID>1</CustomerID>
    <Name>John Doe</Name>
    <Email>john@example.com</Email>
    <OrderAmount>100</OrderAmount>
  </Customer>
  <Customer>
    <CustomerID>2</CustomerID>
    <Name>Jane Smith</Name>
    <Email>jane@example.com</Email>
    <OrderAmount>150</OrderAmount>
  </Customer>
  <Customer>
    <CustomerID>3</CustomerID>
    <Name>Emily Davis</Name>
    <Email>emily@example.com</Email>
    <OrderAmount>200</OrderAmount>
  </Customer>
</Customers>
```



강의에 활용할 데이터

- 2016년 1월 1일부터 2019년 3월 31일까지의 서울대공원 입장객 데이터
- 조류독감으로 인해 2016년 12월 18일부터 2017년 3월 27일까지 폐쇄되어 기록이 없음
- 입장객의 수와 분류, 공휴일 여부와 날씨 등이 기록되어 있음
- data라는 폴더 안에 "seoul_park.csv"파일로 저장되어 있음 (CSV 형식)

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256



seoul_park.csv

데이터 불러오기: read_csv(), read_excel()

- 파일로 저장 되어있는 데이터를 불러와서 데이터프레임으로 저장
- .csv 파일로 저장 되어있는 데이터는 read_csv() 사용
- .xlsx 등의 파일로 저장되어 있는 데이터는 read_excel() 사용

```
df=pd.read_csv('data/seoul_park.csv')
```

data 폴더 안에 있는 seoul_park.csv파일을
불러와 변수 df에 데이터프레임 형태로 저장



다양한 유형의 데이터 불러오기

이 외에도 다양한 형식의 데이터 파일을 pandas를 활용하여 불러올 수 있음

```
pd.read_excel() # xls, xlsx, xlsxm, xlsb, odf, ods, odt  
pd.read_json() # json  
pd.read_xml() # xml  
pd.read_parquet() # parquet  
pd.read_orc() # orc  
pd.read_sql() # sql
```


데이터 일부 확인 : head(), tail()

데이터프레임의 앞 뒤 n개의 데이터를 확인하는데 사용

`df.head(n)`

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256

`df.tail(n)`

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
1081	2019-03-27	X	구름 많음	504	464	10	30	21	-	613	1,117
1082	2019-03-28	X	구름 많음	761	687	46	28	35	108	904	1,665
1083	2019-03-29	X	구름 조금	1,644	1,447	120	77	14	188	1,226	2,870
1084	2019-03-30	O	흐림	1,539	1,326	44	169	29	115	913	2,452
1085	2019-03-31	O	구름 조금	3,061	2,563	111	387	53	-	1,357	4,418

n을 작성하지 않으면 기본적으로는 5



데이터 정보 확인 : info()

- 데이터의 정보를 확인하는데 사용
- 어떤 컬럼이 있는지, 몇 개의 값이 있는지, 어떤 형태로 저장되어 있는지 확인 가능

df.info()

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256

```
<class 'pandas.DataFrame'>
RangeIndex: 1086 entries, 0 to 1085
Data columns (total 11 columns):
#   Column      Non-Null Count  Dtype
---  -
0   날짜        1086 non-null   str
1   공휴일      1086 non-null   str
2   날씨        946 non-null    str
3   유료합계    1086 non-null   str
4   어른       1086 non-null   str
5   청소년     1081 non-null   str
6   어린이     1086 non-null   str
7   외국인     1086 non-null   str
8   단체       1086 non-null   str
9   무료합계    1086 non-null   str
10  총계       1086 non-null   str
dtypes: str(11)
memory usage: 93.5 KB
```



데이터 크기 확인 : shape

- 데이터프레임의 (행 개수, 열 개수)를 튜플로 알려줌
- 함수가 아닌 속성이라 괄호 없이 사용

```
df.shape
```

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256

(1086, 11)



데이터프레임에서 특정 컬럼 추출

데이터프레임에서 컬럼이름을 활용해 특정 컬럼을 시리즈 형태로 추출 가능

```
df["컬럼이름"]
```

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256
...	...	...	...	...	...	...	...	...	...	...	...
1081	2019-03-27	X	구름 많음	504	464	10	30	21	-	613	1,117
1082	2019-03-28	X	구름 많음	761	687	46	28	35	108	904	1,665
1083	2019-03-29	X	구름 조금	1,644	1,447	120	77	14	188	1,226	2,870
1084	2019-03-30	O	흐림	1,539	1,326	44	169	29	115	913	2,452
1085	2019-03-31	O	구름 조금	3,061	2,563	111	387	53	-	1,357	4,418

```
df["어른"]
```

```
0      2799
1      4370
2      2571
3        602
4        319
...
1081     464
1082     687
1083    1447
1084    1326
1085    2563
...
```




데이터프레임에서 특정 컬럼 추출

데이터프레임에서 컬럼이름을 활용해 특정 컬럼을 시리즈 형태로 추출 가능

```
df["컬럼이름"]
```

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256
...	...	...	...	...	...	...	...	...	...	...	...
1081	2019-03-27	X	구름 많음	504	464	10	30	21	-	613	1,117
1082	2019-03-28	X	구름 많음	761	687	46	28	35	108	904	1,665
1083	2019-03-29	X	구름 조금	1,644	1,447	120	77	14	188	1,226	2,870
1084	2019-03-30	O	흐림	1,539	1,326	44	169	29	115	913	2,452
1085	2019-03-31	O	구름 조금	3,061	2,563	111	387	53	-	1,357	4,418

```
df["청소년"]
```

```
0      141
1      203
2      128
3      NaN
4       35
...
1081     10
1082     46
1083    120
1084     44
1085    111
```



NaN : Not a Number

Not a Number의 약자로 **결측값**(비어 있는 값, 빠진 값)을 나타냄

0	141
1	203
2	128
3	NaN
4	35
...	
1081	10
1082	46
1083	120
1084	44
1085	111

- CSV·엑셀 파일을 읽었는데 **원래 셀이 비어 있던** 경우
- 서로 다른 데이터를 **병합**했는데 한쪽에만 있는 행이 생긴 경우
- 계산 중 **정의되지 않은 결과**가 나온 경우 (예: 0/0)

실수(float)로 취급

NaN끼리는 같지 않음

NaN과의 연산 시, 결과가 NaN으로 나옴

데이터프레임에서 특정 여러 컬럼 추출

리스트를 활용하면 여러 개의 컬럼을 데이터프레임 형태로 추출 가능

컬럼의 이름들을 리스트로 묶어주는 대괄호

```
df[["컬럼이름1", "컬럼이름2"]]
```

df에서 추출할 컬럼들을 지정하는 대괄호

	날짜	공휴일	날씨	유료합계	어른	청소년	어린이	외국인	단체	무료합계	총계
0	2016-01-01	O	구름 조금	3,359	2,799	141	419	47	0	1,023	4,382
1	2016-01-02	O	구름 많음	5,173	4,370	203	600	100	111	2,092	7,265
2	2016-01-03	O	구름 많음	3,008	2,571	128	309	91	0	1,549	4,557
3	2016-01-04	X	구름 많음	890	602	NaN	235	51	223	800	1,690
4	2016-01-05	X	구름 많음	416	319	35	62	43	47	840	1,256
...	...	...	...	...	...	...	...	...	...	...	...
1081	2019-03-27	X	구름 많음	504	464	10	30	21	-	613	1,117
1082	2019-03-28	X	구름 많음	761	687	46	28	35	108	904	1,665
1083	2019-03-29	X	구름 조금	1,644	1,447	120	77	14	188	1,226	2,870
1084	2019-03-30	O	흐림	1,539	1,326	44	169	29	115	913	2,452
1085	2019-03-31	O	구름 조금	3,061	2,563	111	387	53	-	1,357	4,418

```
df[["공휴일", "어른"]]
```

	공휴일	어른
0	O	2,799
1	O	4,370
2	O	2,571
3	X	602
4	X	319
...	...	...
1081	X	464
1082	X	687
1083	X	1,447
1084	O	1,326
1085	O	2,563

해당 컬럼에 값들이 몇 개씩 저장되어 있는지 알고 싶을 때 사용

```
df["컬럼이름"].value_counts()
```

```
df["날씨"].value_counts()
```



날씨		
구름 많음		277
구름 조금		236
맑음		222
비		101
흐림		100
눈		6
눈/비		4

Name: count, dtype: int64